DANA PREDICTOR

Mapa de riesgo de inundación urbana



Grupo 10 Proyecto Final de Big data e Inteligencia Artificial

Dennis Bonila

Rafael Chambilla

Víctor Martínez

Jaume Palau

1. Título del proyecto e integrantes 3

2. Resumen ejecutivo 3

3. Descripción funcional del sistema 4

3.1. Flujo general de uso 4

3.2. Casos principales de usuario 4

3.3. Alcance y limitaciones 4

4. Alcance definitivo (IN/OUT) 5

4.1. Funciones mínimas obligatorias 5

4.2. Funciones opcionales 5

4.3. No incluye 6

4.4. Criterios de éxito 6

5. Arquitectura del sistema (alto nivel) 6

5.1. Diagrama de arquitectura 7

5.2. Componentes 7

5.3. Flujo de datos 7

5.4. Almacenamiento de datos 8

5.5. Despliegue 8

6. Tecnologías seleccionadas 9

7. Modelo de datos 9

7.1. Entidades 9

8. Datos 10

8.1. Tipología y volumen de los datos 10

8.2. Calidad y riesgos de los datos 11

8.3. Datos reales, derivados y simulados 11

8.4. Fuentes de referencia 11

9. Ética, legalidad y accesibilidad 12

9.1. Datos personales (PII) 12

9.2. GDPR 12

9.3. Licencias y condiciones de uso 12

9.4. Riesgos de sesgo y medidas de mitigación 12

9.5. Accesibilidad básica del frontend 13

10. Backlog Inicial 13

11. Plan de trabajo 15

12. Estrategia de desarrollo 15

12.1. Control de versiones 15

12.2. Testing 16

12.3. Validación 16

13. Riesgos técnicos actualizados 16

14. Repositorio del proyecto 17

14.1. Estructura 17

14.2. Contenido del readme 17

1. Título del proyecto e integrantes

Nombre del proyecto: DANA Predictor, mapa de riesgo de inundación urbana en Valencia.

Repositorio: https://github.com/Victorproyecto/IA_Project

Miembro	Rol principal	Responsabilidades
Dennis Adrián Bonilla Carreño	Data	Fuentes, ingesta, limpieza, cuadrícula, estadística, variables y etiquetas.
Jaume Palau Seijas	ML	Análisis exploratorio, modelos, validación, umbrales y prueba retrospectiva.
Víctor Martínez Hinojosa	Platform	Pipeline reproducible, esquema Parquet, tests de datos, Docker, CI en GitHub Actions y repositorio.
Rafael Chambilla Rocha	BI	Dashboard Streamlit, mapa, buscador, accesibilidad y capa de acceso a datos en la interfaz.

2. Resumen ejecutivo

DANA Predictor aborda el riesgo de inundación urbana en Valencia durante episodios de lluvia intensa, como la DANA. Hoy es difícil saber qué zonas concretas de la ciudad son más vulnerables según la lluvia, el terreno y la urbanización.

La solución es una herramienta informativa de apoyo a la decisión basada en aprendizaje automático. Un pipeline integra lluvia, elevación, impermeabilidad, peligrosidad PATRICOVA e inundaciones históricas en una cuadrícula de celdas de 250m. Sobre ella se entrena un modelo (regresión logística como referencia y Random Forest como candidato) que estima un nivel de riesgo Bajo, Medio o Alto por celda, visible en un mapa interactivo para un episodio histórico o un escenario predefinido.

El valor está en convertir datos dispersos en información visual y comprobable. El piloto se considerará válido si alcanza Recall ≥ 0.80 y F1 ≥ 0.70 en validación y supera a los modelos de referencia. La herramienta no emite avisos ni sustituye a las autoridades.

3. Descripción funcional del sistema

DANA Predictor es una aplicación web con un mapa interactivo de la ciudad de Valencia. Para un episodio histórico de lluvia o un escenario predefinido, muestra el nivel de riesgo estimado (Bajo, Medio, Alto) de cada celda de 250x250m mediante un código de colores, junto con la probabilidad estimada, las variables utilizadas y los antecedentes históricos de la zona.

Es una herramienta informativa de apoyo a la decisión, no emite avisos ni sustituye a las autoridades. La clasificación definitiva de niveles depende de los umbrales fijados en la validación del modelo.

3.1. Flujo general de uso

1	El usuario accede a la aplicación cuando desea consultar el riesgo potencial de inundación de una zona, por ejemplo, ante una previsión de lluvias intensas o un preaviso de ES-Alert.
2	Introduce una dirección, calle o barrio en el buscador y selecciona la ubicación que desea consultar.
3	La aplicación muestra la zona seleccionada en un mapa interactivo y representa el nivel de riesgo estimado mediante una escala de colores.
4	El usuario modifica la franja horaria mediante un control deslizante para consultar la evolución prevista del riesgo en función de los datos meteorológicos disponibles.
5	El usuario interpreta la información como apoyo para conocer las zonas potencialmente afectadas, teniendo en cuenta las limitaciones y la incertidumbre de las estimaciones.

3.2. Casos principales de usuario

Caso	**Descripción**
Consulta geográfica	Localizar una calle, barrio o zona y ver su riesgo estimado.
Consulta histórica	Ver los antecedentes de inundación asociados a una zona (episodio, fuente, fracción afectada).
Consulta de episodio	Seleccionar un episodio histórico o un escenario predefinido y ver cómo cambia el mapa.
Identificación de zonas de riesgo	Reconocer visualmente las áreas con mayor susceptibilidad según el modelo.

3.3. Alcance y limitaciones

Puede	**No puede**
Estimar un nivel de riesgo por celda de 250m, agregable por barrio y distrito.	Predecir el nivel de agua por calle ni garantizar que una inundación ocurra.

Buscar direcciones, calles y barrios de Valencia.	Emitir alertas automáticas ni enviar órdenes a organismos públicos.
Funcionar en navegador de escritorio y móvil (web).	Dar resultados a nivel de edificio ni cubrir fuera de la ciudad de Valencia.
Mostrar episodios históricos.	Hacer predicción meteorológica propia.
Mostrar variables, versión del modelo, métricas y limitaciones.	Sustituir los avisos de las autoridades de emergencia ni servir como gestión directa de emergencias.

Las estimaciones dependen de la disponibilidad, actualidad y calidad de los datos, por lo que no deben tomarse como una predicción exacta.

4. Alcance definitivo (IN/OUT)

El piloto cubre únicamente la ciudad de Valencia. La unidad de predicción es la celda de 250×250m, agregable por barrio y distrito.

4.1. Funciones mínimas obligatorias

1	Recopilación de datos de Valencia: lluvia (AEMET y, si se confirma, terreno (IGN/CNIG), impermeabilidad (Copernicus Land), peligrosidad (PATRICOVA) e inundaciones históricas (Copernicus EMS).
2	Pipeline de integración, limpieza, validación, transformación y variables, con almacenamiento en Parquet/GeoParquet.
3	Análisis exploratorio: patrones espaciales y temporales, relación entre precipitación e inundación.
4	Modelos: regresión logística (modelo base a superar) y Random Forest como candidato.
5	Evaluación con Recall, F1-Score como métricas principales, ROC-AUC y matriz de confusión como secundarias.
6	Nivel de riesgo por celda (Bajo, Medio, Alto) con umbrales definidos en validación.
7	Prueba retrospectiva con un episodio histórico de DANA.
8	Capa de acceso a datos entre el almacenamiento y el dashboard.
9	Dashboard con mapa de riesgo, selector de episodio o escenario predefinido y leyenda.
10	Buscador de calle o barrio y consulta histórica.
11	Accesibilidad básica y aviso permanente de uso responsable.

12	Control deslizante de franjas horarias con la previsión de AEMET.

4.2. Funciones opcionales

1	Simulación de escenarios de lluvia definidos por el usuario, siempre rotulados como simulados.
2	Exportación de resultados en CSV o GeoJSON.
3	Modelo adicional (XGBoost o Gradient Boosting) si mejora al Random Forest en validación.
4	API REST de consulta (FastAPI) como capa independiente.

4.3. No incluye

1	Cobertura de Cataluña y del resto de la Comunidad Valenciana (ampliación futura).
2	Predicción meteorológica propia, gestión directa de emergencias y envío de órdenes a organismos públicos.
3	Predicción exacta del nivel de agua por calle y garantía de que la inundación ocurra.
4	Aplicación móvil nativa.

4.4. Criterios de éxito

Se reintroducen los criterios definidos en la primera fase:

- Recall ≥ 0.80 y F1 ≥ 0.70 en validación.
- El modelo elegido debe superar al base de regresión logística, en Recall y F1-Score y a la referencia PATRICOVA.
- El sistema puede generar un nivel de riesgo por zona (Bajo, Medio, Alto).
- En la prueba retrospectiva con un episodio histórico de DANA, las zonas clasificadas como de mayor riesgo muestran una correspondencia razonable con las zonas que resultaron afectadas.

5. Arquitectura del sistema (alto nivel)

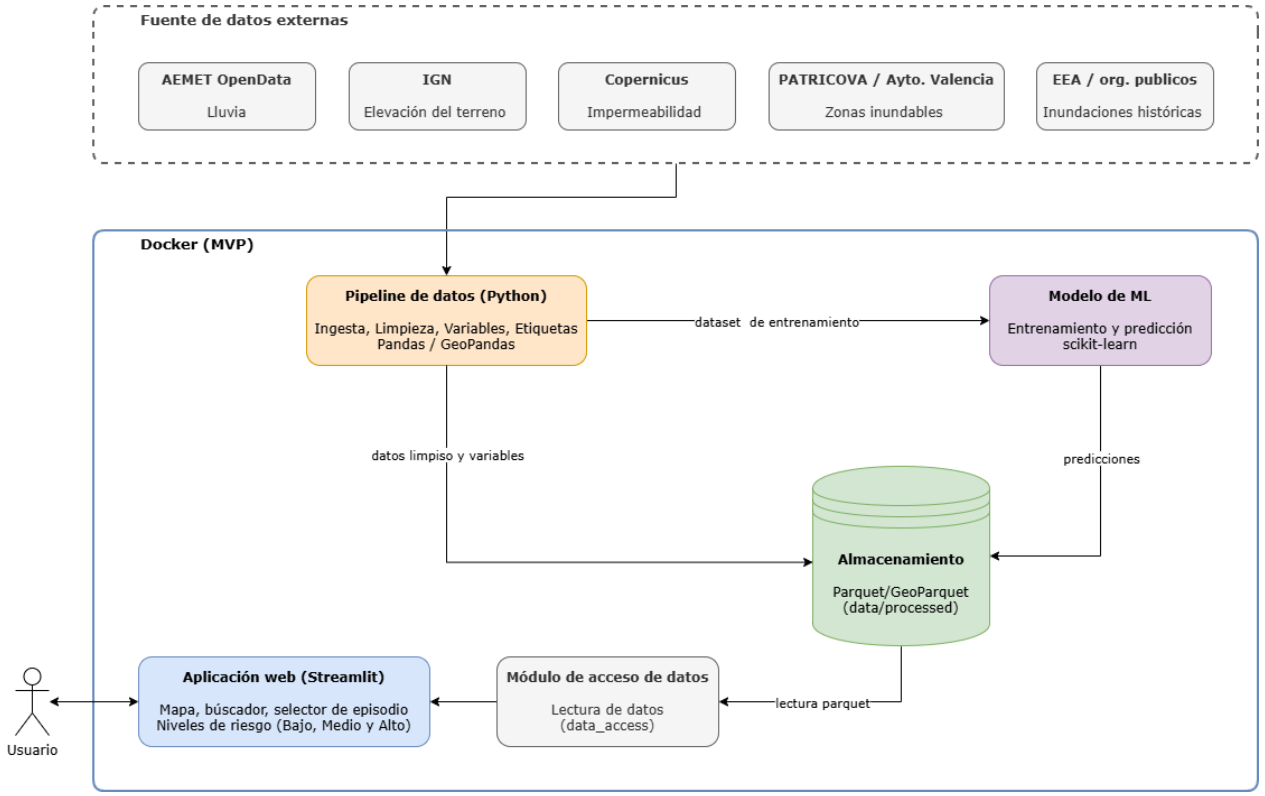
La aplicación permite buscar una dirección o elegir una zona de Valencia y ver su riesgo de inundación para un episodio o escenario. Se plantea una arquitectura modular por capas en la que cada pieza hace una cosa y se puede cambiar sin tocar el resto:

- **Capa de datos:** fuentes externas y almacenamiento en Parquet.
- **Capa de procesamiento:** pipeline de datos.
- **Capa de ML:** entrenamiento y predicción.
- **Capa de acceso a datos:** módulo de acceso a datos.

- **Capa de presentación:** dashboard en Streamlit.

Todo se desarrolla en Python. En el MVP no hay una API ni un backend independiente, Streamlit lee los datos a través del modulo de acceso a datos.

5.1. Diagrama de arquitectura



5.2. Componentes

Componente	Funcionalidad
Pipeline de datos	Scripts en Python (Pandas y GeoPandas) que descargan los datos de las fuentes externas, los limpian, tratan los huecos, calculan las variables del modelo y lo guardan todo en Parquet.
Modelo de ML	Se entrena con scikit-learn a partir de las variables de lluvia, terreno y urbanización, y devuelve una probabilidad de inundación para cada zona.
Almacenamiento	Ficheros Parquet (GeoParquet para las zonas, que tienen geometría) con las zonas, las observaciones meteorológicas, los episodios históricos y las predicciones.
Aplicación web (Streamlit)	Mapa interactivo con buscador de direcciones donde el usuario ve las zonas coloreadas según su nivel de riesgo.

5.3. Flujo de datos

El recorrido de los datos desde que los descargamos hasta que llegan al mapa sería este:

1. **Ingesta:** descargamos la precipitación, los datos del terreno, las zonas inundables y los registros de inundaciones pasadas.
2. **Limpieza:** pasamos todo a un formato común, tratamos los valores que faltan y nos aseguramos de que fechas y coordenadas usan la misma referencia.
3. **Cálculo de variables:** sacamos indicadores como la lluvia acumulada, la pendiente o el porcentaje de suelo urbanizado, y los guardamos en Parquet.
4. **Predicción:** el modelo recibe las variables de una zona y devuelve una probabilidad.
5. **Guardado:** la predicción se guarda en Parquet con la fecha, la zona y la versión del modelo que la ha generado, para poder comparar si más adelante cambiamos de modelo.
6. **Visualización:** la aplicación Streamlit lee esos ficheros y el usuario ve las zonas en el mapa coloreadas según su nivel de riesgo.

5.4. Almacenamiento de datos

Para el MVP no se usa un servidor de base de datos. Los datos procesados se guardan en Parquet (GeoParquet para los que tienen geometría): guarda por columnas y comprimido, respeta los tipos y se lee muy rápido desde Pandas y GeoPandas. Se elige frente a CSV porque este pierde tipos, ocupa más y es más lento, y frente a una base de datos porque, con una sola ciudad y unos pocos años de datos, un servidor costaría más de montar y mantener que lo que aporta.

Los datos brutos se conservan en su formato original (GeoTIFF, JSON, CSV) en data/raw/ solo como entrada del pipeline, nunca alimentan directamente la aplicación.

La decisión no es definitiva: si crece el volumen, se añaden ciudades o se necesitan consultas espaciales frecuentes, se migraría a PostgreSQL con PostGIS. El modelo de datos ya está organizado como tablas con claves, por lo que el cambio sería sencillo.

5.5. Despliegue

El pipeline, el entrenamiento y la aplicación Streamlit se empaquetan con Docker (una imagen, tres puntos de entrada: pipeline, entrenamiento y aplicación) con la carpeta data/ montada como volumen. Pipeline y entrenamiento se lanzan bajo demanda, la aplicación se mantiene en ejecución. No se justifican microservicios ni procesamiento distribuido (Spark) con el volumen esperado.

6. Tecnologías seleccionadas

En la siguiente tabla se describen las tecnologías empleadas, una descripción y una alternativa planteada.

Tecnología	**Descripción**	**Alternativa**
Python	Dispone de un amplio ecosistema de herramientas para el tratamiento de datos y el desarrollo de modelos de IA	R
Pandas, GeoPandas	Biblioteca principal del proyecto debido a que permite integrar datos de diferentes fuentes y construir las tablas necesarias.	Polars
Scikit-learn	Desarrollo y evaluación de modelos de aprendizaje automático, comparación de algoritmos y preparación de los datos mediante técnicas de preprocesamiento.	XGBoost
Streamlit	Desarrollo de una primera interfaz web que permita consultar resultados y visualizar la información sin tener que implementar desde cero un frontend completo. Facilita la creación rápida de un prototipo accesible desde navegadores de escritorio y dispositivos móviles.	Flask

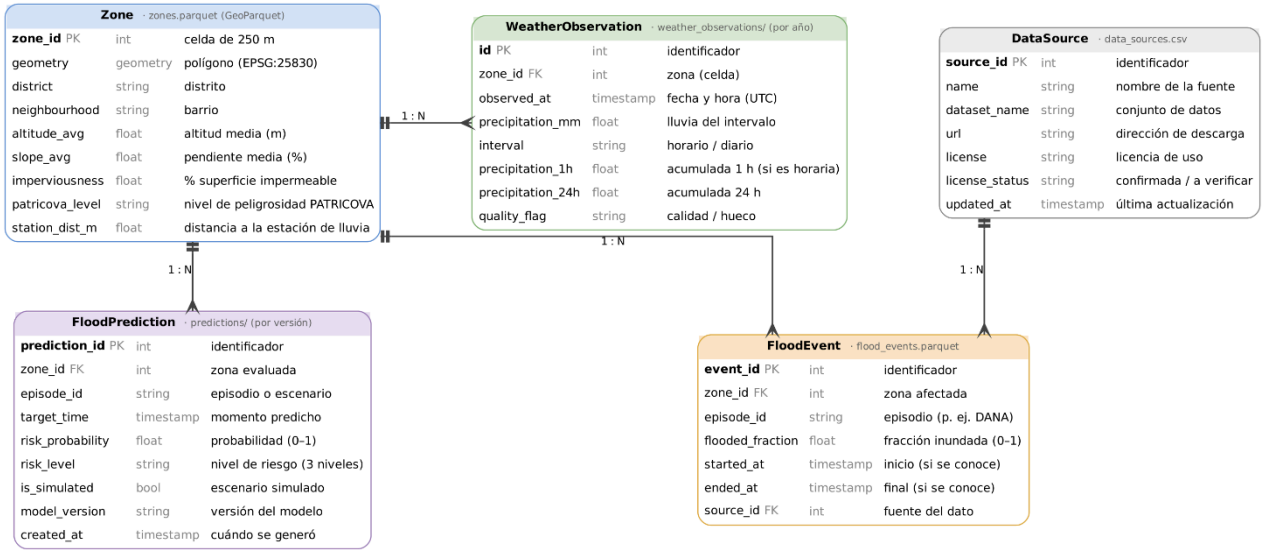
7. Modelo de datos

Todo el modelo gira alrededor de la zona geográfica, que es la celda de 250×250m (agregable por barrio y distrito). Aunque los datos se guarden en Parquet, se organizan como tablas relacionales: cada entidad es un fichero (o una carpeta de ficheros) y se relacionan mediante identificadores. Los nombres de entidades y campos van en inglés para coincidir con el código.

7.1. Entidades

Entidad	**Descripción**
Zone	Celda de 250m con district, neighbourhood, atributos físicos (altitud, pendiente, impermeabilidad), nivel PATRICOVA y estación más cercana. Casi estática: se genera una vez.
WeatherObservation	Lluvia por estación y fecha. La lluvia de cada celda se calcula en el pipeline.
FloodEvent	Inundaciones observadas por celda y episodio. De aquí salen las etiquetas.
FloodPrediction	Resultado del modelo por celda y episodio o escenario, con marca de simulado.

DataSource	Fuente, URL, licencia y estado de verificación de cada dato. Pocas filas, rellenada a mano.



8. Datos

El proyecto utilizará la ciudad de Valencia como territorio piloto para desarrollar y evaluar un modelo de análisis del riesgo de inundación urbana, integrando información geográfica, meteorológica y de infraestructura urbana.

Las fuentes previstas son:

- **PATRICOVA:** identificación de zonas con peligrosidad de inundación y referencia territorial para evaluar el modelo.
- **AEMET:** obtención de datos meteorológicos y previsiones de precipitación para analizar diferentes escenarios.
- **CNIG/IGN:** información topográfica, como elevación, pendiente y modelos digitales del terreno.
- **Ayuntamiento de Valencia:** datos sobre infraestructura urbana y drenaje, sujetos a disponibilidad y nivel de detalle.

La selección definitiva dependerá de la disponibilidad, compatibilidad y utilidad de los datos.

8.1. Tipología y volumen de los datos

Se prevé trabajar con los siguientes tipos de datos:

- **Vectoriales:** zonas inundables, calles, barrios y, si están disponibles, redes de drenaje.
- **Ráster:** modelos digitales del terreno y otras capas geográficas.
- **Tabulares:** registros meteorológicos, características territoriales y variables derivadas.
- **Datos de API:** previsiones meteorológicas y otros datos estructurados, como JSON.

- **Simulados:** escenarios hipotéticos de precipitación para probar el sistema.

El volumen definitivo dependerá de la resolución de las capas, el periodo meteorológico seleccionado y la disponibilidad de datos municipales.

8.2. Calidad y riesgos de los datos

Se identifican los siguientes riesgos y medidas de mitigación:

- **Procesamiento de PATRICOVA:** estudiar su guía técnica para interpretar correctamente la cartografía y extraer variables útiles.
- **Incompatibilidad entre fuentes:** armonizar formatos, sistemas de referencia geográfica, resoluciones y frecuencias temporales.
- **Datos incompletos o insuficientes:** evaluar su cobertura y calidad, documentando las limitaciones.
- **Falta de datos de drenaje:** limitar el análisis a las variables disponibles, sin atribuir al modelo capacidades hidráulicas no justificadas.
- **Ruido y sesgos:** realizar comprobaciones de consistencia y valorar su impacto.
- **Dificultad de integración:** probar inicialmente la combinación de las fuentes mediante un conjunto de datos mínimo viable.

8.3. Datos reales, derivados y simulados

Se distinguirán tres categorías:

1. **Reales:** procedentes directamente de las fuentes originales, como registros meteorológicos y cartografía oficial.
2. **Derivados:** calculados o transformados a partir de los datos originales, como la pendiente del terreno o indicadores territoriales.
3. **Simulados:** generados artificialmente para probar el sistema ante situaciones hipotéticas, incluidos episodios de precipitación intensa.

Se documentará la procedencia y el tratamiento de los datos. Los escenarios simulados se identificarán claramente y no se presentarán como observaciones reales ni como inundaciones históricas. Estas pruebas permitirán evaluar el funcionamiento técnico del prototipo, pero no demostrarán por sí solas su capacidad predictiva real.

8.4. Fuentes de referencia

La disponibilidad de los datos específicos del CNIG/IGN y del Ayuntamiento deberá confirmarse durante la recopilación.

- **PATRICOVA:** Portal oficial de la Generalitat Valenciana.
- **Guía de PATRICOVA:** Documentación técnica.
- **AEMET:** Datos abiertos.
- **Ayuntamiento de Valencia:** Sede electrónica, procedimiento SN.OT.30.

9. Ética, legalidad y accesibilidad

9.1. Datos personales (PII)

El sistema no trata datos personales por diseño. Las fuentes son meteorológicas, geográficas o estadísticas agregadas. De los registros históricos solo se extraen fecha, tipo de episodio y zona, sin nombres, direcciones ni imágenes de personas afectadas. La resolución mínima de salida es la celda de 250m y el dashboard no muestra edificios individuales. La dirección que el usuario escribe en el buscador solo se usa para centrar el mapa: se envía al geocodificador, no se almacena ni se registra, y el piloto no tiene cuentas de usuario ni analítica personal.

9.2. GDPR

Con esta configuración el núcleo del sistema no trataría datos personales y el Reglamento (UE) 2016/679 no sería aplicable, pero se adoptan igualmente la minimización de datos (art. 5.1.c) y la protección de datos desde el diseño (art. 25). El sistema no toma decisiones automáticas.

9.3. Licencias y condiciones de uso

Se priorizarán fuentes oficiales y se comprobarán las condiciones de acceso, reutilización, atribución y distribución antes de incorporar sus datos al proyecto. En particular, se revisarán las condiciones específicas de PATRICOVA, AEMET, CNIG/IGN y del Ayuntamiento de Valencia. Las licencias y la procedencia se documentarán junto a cada conjunto de datos.

9.4. Riesgos de sesgo y medidas de mitigación

Riesgo	**Cómo se manifiesta**	**Mitigación**
Representatividad de episodios	Pocos episodios extremos, el modelo puede no generalizar a lluvias moderadas.	Validación por episodio o bloques espaciales, aviso de extrapolación; no presentar los resultados como validación general.
Sesgo espacial de la lluvia	Pocas estaciones, la previsión de AEMET es municipal y no distingue barrios.	Distancia máxima en la asignación, variable station_dist_m y mensaje claro sobre la limitación.
Desequilibrio de clases	Pocas celdas afectadas frente a no afectadas.	Pesos de clase, Recall y F1 como métricas principales, umbral elegido en validación.
Dependencia de PATRICOVA	Es una peligrosidad modelada y puede no coincidir con lo ocurrido.	Usarla como variable y referencia, no como verdad observada.

Equidad entre zonas	Algunos distritos podrían estar sistemáticamente subestimados.	Informe de falsos negativos por district, con la salvedad de la muestra pequeña.
Estigmatización	Un barrio marcado como Alto puede sufrir efectos en valor de vivienda o seguros.	Nivel presentado como riesgo estimado, sin publicación a nivel de edificio.
Sobreconfianza o alarma	Se sigue el color del mapa sin criterio o se interpreta como aviso oficial.	Mensaje permanente *"herramienta informativa que no sustituye los avisos de las autoridades"*, probabilidad visible junto al nivel, versión del modelo y métricas a la vista.

9.5. Accesibilidad básica del frontend

El objetivo es cumplir el nivel AA de las WCAG 2.1 en los elementos propios del dashboard:

- El color nunca es el único canal: paleta apta para daltonismo, etiqueta textual del nivel y una tabla alternativa ordenable de zonas por nivel.
- Contraste mínimo de 4.5:1 en texto y leyenda.
- Controles nativos de Streamlit, operables con teclado. El mapa no lo es por completo, y la tabla alternativa cubre esa carencia.
- Interfaz en español y sin elementos parpadeantes.
- Aviso permanente de uso responsable visible en todas las vistas.

10. Backlog Inicial

Historia	**Criterios de aceptación**
Como ingeniero de datos, quiero recopilar los datos de lluvia, terreno, impermeabilidad, peligrosidad e inundaciones históricas de Valencia para disponer de una base común de trabajo.	• Se descargan datos de AEMET, IGN/CNIG, Copernicus Land, Copernicus EMS y PATRICOVA. • Cada fuente queda documentada en DataSource con licencia y estado. • Los datos brutos se guardan sin modificar en data/raw/. • Se hace el conteo de celdas inundadas y se registran.
Como científico de datos, quiero integrar y transformar los datos para generar un conjunto coherente de análisis.	• Todo en EPSG:25830, con unidades y formatos homogéneos. • Sin duplicados y con huecos tratados y marcados. • Estadística zonal calculada por celda de 250 m. • Tabla de entrenamiento con etiquetas en Parquet. • Tests de datos pasados (claves, CRS, fechas).

Como científico de datos, quiero realizar un análisis exploratorio para identificar patrones espaciales y temporales relacionados con las inundaciones.	• Distribuciones y correlaciones de las variables. • Relación entre lluvia y celdas inundadas, con al menos un gráfico. • Al menos tres conclusiones documentadas que afecten a la elección de variables.
Como científico de datos, quiero entrenar modelos para estimar el riesgo de cada zona.	• Regresión logística y Random Forest implementados. • Mismos conjuntos de entrenamiento y validación para todos. • Cada experimento registrado con parámetros, datos y métricas.
Como científico de datos, quiero evaluar los modelos para seleccionar la mejor solución.	• Se calculan Recall, F1 y ROC-AUC y matriz de confusión. • Umbral elegido en validación, no en prueba. • Criterio de éxito: Recall ≥ 0.80, F1 ≥ 0.70.
Como usuario, quiero un nivel de riesgo por celda (Bajo, Medio, Alto) para interpretar la probabilidad rápidamente.	• Umbrales de probabilidad definidos en validación y documentados. • Cada celda tiene risk_level y risk_probability.
Como científico de datos, quiero una prueba retrospectiva con un episodio histórico de DANA para comprobar el modelo en un caso real.	• El episodio se excluye del entrenamiento o se valida por bloques. • Se compara el mapa predicho con las celdas inundadas observadas. • Se informan Recall, F1 y falsos negativos por distrito.
Como desarrollador, quiero una capa de acceso a datos (data_access) para desacoplar el dashboard del almacenamiento.	• Funciones para consultar zonas, predicciones y antecedentes por zona y episodio. • El dashboard no lee los Parquet directamente. • Tests unitarios con los datos de muestra.
Como usuario, quiero ver un mapa de riesgo y elegir un episodio histórico o escenario predefinido para identificar las zonas más vulnerables.	• El mapa muestra niveles Bajo, Medio y Alto con leyenda. • Selector de episodio o escenario; los escenarios aparecen rotulados como simulados.
Como usuario, quiero una interfaz accesible y un aviso de uso responsable para no malinterpretar el riesgo.	• El nivel aparece también como texto. • Tabla alternativa ordenable por nivel. • Contraste ≥ 4,5:1. • Aviso permanente *"herramienta informativa que no sustituye los avisos de las autoridades"*. • Buscador y selectores operables con teclado.

11. Plan de trabajo

El proyecto se desarrollará de forma progresiva, coordinando el trabajo mediante dos reuniones semanales en *Discord* y manteniendo una comunicación continua por *WhatsApp*.

Semana	Trabajo principal	Hito
1- 2	Datos y preparación	Dataset preparado
3-4	EDA y modelo ML	Primer modelo
5-6	Evaluación e integración	Modelo validado
7-8	Dashboard y pruebas	Sistema integrado
9	Documentación y revisión	Entrega final

Dependencias: la preparación de los datos es necesaria antes del entrenamiento del modelo. El modelo debe validarse antes de integrarlo en el sistema y el dashboard.

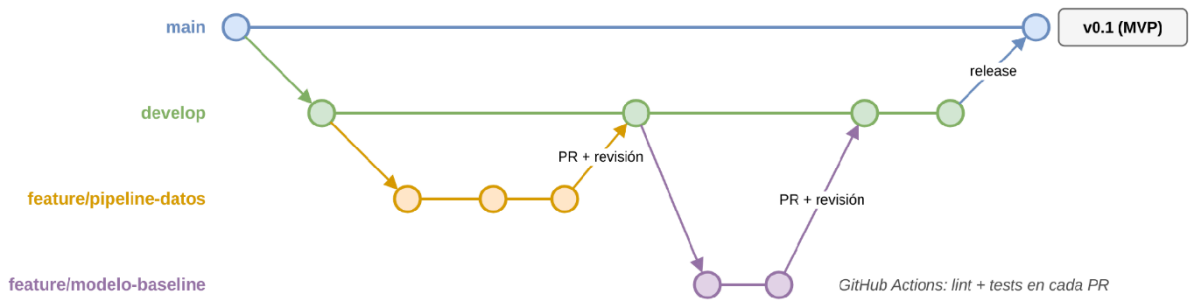
Reparto: Dennis – Data, Víctor – ML, Jaume – Platform y Rafa – BI.

Riesgos técnicos: disponibilidad y calidad de los datos, integración de fuentes y resultados insuficientes del modelo. Se mitigarán simplificando las variables o el alcance cuando sea necesario.

12. Estrategia de desarrollo

12.1. Control de versiones

Todo el código estará en el repositorio IA_Project de GitHub, al que tenemos acceso los cuatro miembros. Nadie sube cambios directamente a main ni a develop: cada tarea va en su propia rama y entra mediante un pull request que revisa otro compañero.



Seguimos un Git Flow simplificado: *main* guarda la versión estable que entregamos al cerrar cada hito (etiquetas v0.1, v0.2…), *develop* integra lo terminado. Los commits siguen Conventional Commits (feat, fix, docs, test, refactor). No subimos datos ni credenciales: solo los scripts que generan los datos, una muestra pequeña para los tests y la API key de AEMET en un .env incluido en el .gitignore.

12.2. Testing

En un proyecto de Machine Learning hay que probar el código, los datos y el modelo, por eso separamos las pruebas en cuatro tipos:

Tipo de prueba	Qué comprobamos	Ejemplo
Unitarias	Funciones sueltas del pipeline y de la aplicación.	La lluvia acumulada en 24h se calcula bien.
De datos	Esquema y valores de los Parquet; sustituyen a las claves foráneas.	Sin lluvias negativas y cada zone_id existe en zones.parquet.
De integración	Que las piezas funcionan juntas.	Pipeline completo con la muestra y Streamlit cargando los Parquet.
Del modelo	Que entrena y da resultados con sentido.	Con un dataset pequeño, probabilidades entre 0 y 1.

No buscamos un 100 % de cobertura, pero sí tests en las partes críticas (cálculo de variables y construcción de etiquetas), porque un error ahí estropearía el modelo sin que lo notáramos. El frontend se prueba a mano con los criterios de aceptación de las historias de usuario.

12.3. Validación

Modelo: división temporal: entrenamos con los episodios antiguos y evaluamos con los recientes, comparando con un modelo base de umbral de lluvia acumulada. Métricas: recall, precisión y área bajo la curva precisión-recall, dando prioridad al recall.
Aplicación: al cerrar cada hito revisamos juntos las historias terminadas contra sus criterios de aceptación antes de pasar *develop* a main.

13. Riesgos técnicos actualizados

Riesgo	Impacto	Probabilidad	Plan de mitigación
Falta o baja calidad de datos	Alto	Media	Buscar fuentes alternativas y reducir variables.

Dificultad para integrar los datos	Medio	Media	Simplificar el pipeline y estandarizar los datos.
Modelo con resultados insuficientes	Alto	Media	Probar otros modelos y revisar las variables utilizadas.
Retrasos en el desarrollo	Medio	Baja	Priorizar las funcionalidades mínimas del proyecto.
Problemas en la integración final	Medio	Baja	Realizar pruebas e integración progresiva.

14. Repositorio del proyecto

14.1. Estructura

```
IA_Project/
├── docs/
│   ├── Fase0_Presentacion_alineacion_viabilidad_Grupo10.pdf
│   ├── Fase1_grupo10.pdf
├── src/
│   ├── pipeline/
│   ├── models/
│   ├── data_access/
│   └── app/
├── tests/
├── data/
│   ├── raw/
│   └── processed/
├── environment/
├── README.md
└── .gitignore
```

14.2. Contenido del readme

1. **Descripción del proyecto:** qué es DANA Predictor y su carácter informativo.
2. **Integrantes y roles.**
3. **Arquitectura resumida:** capas, componentes y docs/arquitectura.png.
4. **Tecnologías:** Python, Pandas, GeoPandas, scikit-learn, Streamlit y Docker.
5. **Fuentes y licencias.**